

Universite Hassan II de Casablanca

Faculte des Sciences Ben M'Sick — Departement de Mathematiques et Informatique



DEMONSTRATION ACADEMIQUE

Capacites Reelles du Chatbot Intelligent FSBM

Matrice des questions, moteurs de reponse, limites, et scenarios de soutenance

Realise par : Akram BELMOUSSA · Zakaria BENGHAZALE · Nouhaila BEN SOUMANE

Encadre par : Pr. Habib BENLAHMER — Co-encadre par : Pr. Salma HANNOUNI

Licence en Developpement Informatique — Annee universitaire 2025-2026

Sommaire

Chapitre 1 · Introduction a la Demonstration	5
1.1 Les moteurs de reponse reels du systeme	5
1.2 Langues reellement supportees	5
Chapitre 2 · Partie 1 — Matrice des Questions du Chatbot	6
Chapitre 3 · Partie 2 — Demonstration Trilingue	8
3.1 Categorie Etudes — Filieres	8
Francais	8
Darija	8
Anglais	8
3.2 Categorie Administration — Inscription	8
Francais	8
Darija	9
Anglais	9
3.3 Categorie Conversationnel — Accueil et soutien	9
Darija	9
Francais	9
Chapitre 4 · Partie 3 — Comparaison des Moteurs	11
Chapitre 5 · Partie 4 — Limites du Chatbot	12
5.1 Limites de la FAQ	12
5.2 Limites du TF-IDF	12
5.3 Limites de Groq	12
5.4 Limites de LLaMA (repli)	12
5.5 Limites globales	13
Chapitre 6 · Partie 5 — Importance de la FAQ	14
6.1 Sans FAQ : le risque d'hallucination	14

6.2 Avec FAQ : la garantie d'exactitude	14
6.3 Schema de decision du systeme	14
Chapitre 7 · Partie 6 — Scenarios de Demonstration	16
Chapitre 8 · Partie 7 — Questions Potentielles du Jury	18

01 CHAPITRE

Chapitre 1 · Introduction a la Demonstration

Ce document presente, de maniere academique et honnete, les **capacites reelles** du chatbot intelligent de la FSBM, ses **moteurs de reponse**, ses **limites**, et l'apport determinant de la **base de connaissances (FAQ)**. Les exemples et niveaux de fiabilite presentes ont ete obtenus en **interrogeant directement le moteur reel** (classifieur TF-IDF) sur des questions concretes.

1.1 Les moteurs de reponse reels du systeme

Tableau 1 — Moteurs de reponse reellement implements

Moteur	Role reel dans le projet
FAQ / TF-IDF	Classifieur d'intentions trilingue (28 intentions, ~835 patterns). Reponses predefinites fiables.
Base de connaissances FSBM	Donnees reelles (6 departements, filieres, 239 profs, doyen) + fsbm_knowledge.json.
Groq (LLaMA 3.3-70B)	Grand modele de langage, mode avance, encadre par RAG.
HuggingFace (LLaMA 3 8B)	Modele de repli (fallback) si Groq indisponible.
RAG	Recuperation TF-IDF des contextes + generation : limite les hallucinations.

[*] Important : il n'existe pas de modele LLaMA execute en local dans ce projet. Le terme "LLaMA" designe le modele **LLaMA 3.3-70B accessible via l'API Groq** et le modele de repli **LLaMA 3 8B via HuggingFace**. La colonne "LLaMA" des tableaux correspond donc au repli generatif.

1.2 Langues reellement supportees

Le chatbot prend en charge **trois langues**, confirmees par le code (`SUPPORTED_LANGS = [fr, en, darija]`) : le **francais**, l'**anglais**, et la **darija marocaine** (arabe dialectal, graphie latine et arabe). Il ne s'agit pas de l'arabe standard (MSA) mais bien du dialecte reellement parle par les etudiants.

02 CHAPITRE

Chapitre 2 · Partie 1 — Matrice des Questions du Chatbot

Le tableau ci-dessous croise des **questions réelles** par catégorie avec le comportement **réellement observé** du moteur FAQ/TF-IDF (intention détectée et score de confiance mesurés en direct), le comportement du mode génératif (Groq/RAG) et le niveau de fiabilité. Les cas où la FAQ se trompe sont présentés en toute transparence : ils justifient le complément génératif.

[i] Légende fiabilité : **Élevée** = intention correcte, confiance $\geq 0,80$. **Moyenne** = intention approximative, confiance 0,40-0,80. **Faible** = hors corpus ou mauvaise intention (le mode Groq+RAG prend alors le relais).

Tableau 2 — Matrice réelle des questions et des moteurs de réponse

Catégorie	Question réelle	FAQ / TF-IDF (mesure)	Groq / RAG	Fiabilité
Administration	Où se trouve le service de scolarité ?	stage_pfe (0,44) — INCORRECT	Réponse correcte (RAG + base)	Faible (FAQ)
Administration	Comment obtenir une attestation ?	diplome (0,58) — approximatif	Reformulation ciblée	Moyenne
Administration	Comment retirer mon diplôme ?	diplome (1,00) — correct	Idem (contexte RAG)	Élevée
Études	Quelles sont les filières disponibles ?	filières (0,76) — correct	Liste + conseils	Élevée
Études	Quels sont les modules du semestre ?	filières (0,58) — pas d'intent dédiée	Réponse via base modules	Moyenne
Enseignants	Qui dirige le département informatique ?	filiere_di (0,55) — approximatif	Pr. ADNAOUI Khalid (base réelle)	Moyenne
Enseignants	Domaines de recherche d'un professeur ?	hors corpus FAQ	Base Scholar (5 profs réels)	Moyenne
Horaires	Où trouver les emplois du temps ?	emploi_du_temps (0,55) — correct	Idem + liens	Élevée
Horaires	Quand commencent les examens ?	examens (1,00) — correct	Idem (contexte)	Élevée
Recherche	Publications d'un enseignant ?	hors corpus FAQ	Base Scholar (Benlahmer : 2785 cit.)	Moyenne

Categorie	Question reelle	FAQ / TF-IDF (mesure)	Groq / RAG	Fiabilite
Orientation	Quelle filiere choisir ?	filieres (1,00) — liste	Conseil personnalise (generatif)	Elevee
Orientation	Quels sont les debouches ?	partiel (careers en base)	Synthese generative (RAG)	Moyenne
General	Presente la FSBM	identite_chatbot (0,82)	Presentation + base (doyen, 239 profs)	Elevee
General	Presente l'Universite Hassan II	hors corpus FAQ	Reponse generative (Groq)	Moyenne

Cette matrice illustre la **complementarite** des moteurs : la FAQ excelle sur les questions frequentes et bien formulees (examens, inscription, bourses : confiance 1,00), tandis que le mode generatif encadre par RAG prend le relais pour les questions hors corpus ou mal classees, en s'appuyant sur la base de donnees reelle de la FSBM.

03 CHAPITRE

Chapitre 3 · Partie 2 — Demonstration Trilingue

Le chatbot detecte automatiquement la langue et repond dans celle-ci. Les echanges ci-dessous sont des **reponses reelles** du moteur (extraits), pour le francais, la darija marocaine et l'anglais — les trois langues effectivement supportees.

3.1 Categorie Etudes — Filieres

Francais

Tableau 3 — Echange reel — FR

Question (FR)	Quelles sont les filieres disponibles ?
Reponse reelle du chatbot	La FSBM propose 7 licences + 18 masters : SMI Sciences Math & Informatique, DI Developpement Informatique...

Darija

Tableau 4 — Echange reel — Darija

Question (Darija)	shno hia les filieres ?
Reponse reelle du chatbot	La FSBM propose 7 licences + 18 masters : SMI, DI, SMA... (detecte et repond)

Anglais

Tableau 5 — Echange reel — EN

Question (EN)	What are the available programs?
Reponse reelle du chatbot	I'm the FSBM Smart Chatbot! I can help you with Registration, Programs & Masters, Schedules & Exams...

3.2 Categorie Administration — Inscription

Francais

Tableau 6 — Echange reel — FR

Question (FR)	Comment s'inscrire a la FSBM ?
Reponse reelle du chatbot	Inscription FSBM - etapes : 1. Preinscription en ligne sur preins.univh2c.ma. Remplis le formulaire...

Darija

Tableau 7 — Echange reel — Darija

Question (Darija)	kifash ndir l'inscription ?
Reponse reelle du chatbot	Tassjil f FSBM - l'etapes b tafassil : 1. Preinscription online : Mchi l preins.univh2c.ma o kml lformulaire...

Anglais

Tableau 8 — Echange reel — EN

Question (EN)	How do I register at FSBM?
Reponse reelle du chatbot	FSBM Enrollment - Step-by-step: 1. Online pre-registration: Go to preins.univh2c.ma. Fill the form...

3.3 Categorie Conversationnel — Accueil et soutien

Darija

Tableau 9 — Echange reel — Darija

Question (Darija)	salam, ki dayer ?
Reponse reelle du chatbot	L7amdulilah khoya ! Ana mzyan, jaheh n3awnek f ay haja. Wach kayna chi haja li bghiti tssawel ?

Francais

Tableau 10 — Echange reel — FR

Question (FR)	Je suis stresse pour les examens
Reponse reelle du chatbot	Je te comprends, le stress des examens est tres commun. Methode : Pomodoro 25 min + 5 min pause, annales...

[+] La prise en charge de la **darija** (461 patterns) et la **personnalisation** (formules khoya/khti selon le genre detecte) constituent des apports originaux rarement presents dans les chatbots generalistes.

04 CHAPITRE

Chapitre 4 · Partie 3 — Comparaison des Moteurs

Le tableau suivant compare les trois moteurs selon des criteres operationnels. "LLaMA" designe ici le repli generatif (LLaMA 3 8B via HuggingFace).

Tableau 11 — Comparaison des moteurs de reponse

Critere	FAQ / TF-IDF	Groq (LLaMA 3.3-70B)	LLaMA (repli HF 8B)
Rapidite	Tres rapide (~30 ms)	Rapide (~150-250 ms)	Lent (~1-3 s)
Cout	Nul (local)	Gratuit (quota)	Gratuit (quota)
Precision (FSBM)	Elevee si dans le corpus	Elevee avec RAG	Moyenne
Reponses generales	Faible (corpus borne)	Tres bonne	Bonne
Multilingue	FR / EN / Darija	Oui (large)	Oui
Maintenance	Mise a jour du dataset	Aucune (API)	Aucune (API)
Dependance Internet	Aucune	Oui (API)	Oui (API)
Explicabilite	Elevee (intention + score)	Faible (boite noire)	Faible
Risque d'hallucination	Nul	Reduit par RAG	Reduit par RAG

Aucun moteur n'est superieur en tout : le systeme combine leurs forces via une **cascade** (Groq, puis HuggingFace, puis TF-IDF) garantissant rapidite, fiabilite et **disponibilite de 100 %**.

05 CHAPITRE

Chapitre 5 · Partie 4 — Limites du Chatbot

Une presentation academique honnete exige d'exposer clairement les limites du systeme. Elles sont reelles et documentees ci-dessous.

5.1 Limites de la FAQ

- Ne repond qu'aux **sujets presents dans le corpus** (28 intentions).
- **Ne raisonne pas** : elle reconnait une intention, elle ne deduit pas.
- **N'invente jamais** de reponse — ce qui est une force pour la fiabilite, une limite pour la couverture.
- Exemple reel observe : "modules du semestre" est classe en *filieres* faute d'intention dediee.

5.2 Limites du TF-IDF

- Repose sur la **correspondance lexicale** : sensible aux mots-cles et reformulations.
- Depend de la **qualite et de la couverture du corpus** par langue.
- Exemple reel : "Ou se trouve le service de scolarite ?" mal classe (stage_pfe, 0,44) car proche lexicalement.
- Comprehension **semantique limitee** (pas d'embeddings neuronaux dans ce moteur).

5.3 Limites de Groq

- **Necessite une connexion Internet** (API distante).
- Depend d'un **service externe** (disponibilite, conditions d'usage).
- **Cout potentiel futur** au-dela des quotas gratuits.
- Risque residuel d'**hallucination**, attenuie mais non nul, controle par le RAG.

5.4 Limites de LLaMA (repli)

- Un deploiement **local** exigerait des **ressources materielles** importantes (GPU, RAM).
- **Consommation memoire** et **temps de calcul** eleves pour les grands modeles.
- Le repli HuggingFace est **plus lent** (~1-3 s) que Groq.

5.5 Limites globales

- **Donnees manquantes** : certaines informations (modules detailles) ne sont pas publiees.
- **Mises a jour necessaires** : la base doit etre tenue a jour (annonces, calendriers).
- **Informations potentiellement obsoletes** si la base n'est pas rafraichie.
- La qualite des reponses generatives depend de la **qualite des contextes** recuperes (RAG).

06 CHAPITRE

Chapitre 6 · Partie 5 — Importance de la FAQ

Une question centrale du jury sera : *pourquoi conserver une FAQ alors qu'un grand modele de langage existe ?* La reponse tient en un mot : la **fiabilite institutionnelle**.

6.1 Sans FAQ : le risque d'hallucination

Un grand modele de langage seul, interroge sur des informations universitaires precises (dates d'examens, procedures, responsables), peut :

- **Halluciner** : produire une reponse fausse mais plausible.
- **Inventer** des donnees universitaires (dates, noms, montants) inexistantes.
- Induire l'etudiant en erreur sur des demarches administratives sensibles.

6.2 Avec FAQ : la garantie d'exactitude

- Fournit des **reponses verifiees** et controlees par l'administration.
- Garantit l'**exactitude institutionnelle** sur les sujets cles.
- **Reduit les hallucinations** : le RAG fournit au modele des contextes fiables a reformuler.
- Ameliore la **confiance** de l'utilisateur et la credibilite du service.

6.3 Schema de decision du systeme




Figure 1 — Architecture de decision : la FAQ d'abord, le generatif encadre ensuite

[*] La FAQ n'est pas en concurrence avec le LLM : elle le **fiabilise**. Le LLM apporte le naturel et la couverture ; la FAQ et le RAG apportent l'exactitude. C'est la combinaison qui fait la valeur du systeme.

07 CHAPITRE

Chapitre 7 · Partie 6 — Scenarios de Demonstration

Voici 30 scenarios prêts à être joués lors de la soutenance, couvrant les moteurs et les langues. Pour chacun : la question, la réponse attendue, le moteur sollicité et l'objectif pédagogique.

Tableau 12 — 30 scenarios de demonstration pour la soutenance

#	Question	Reponse attendue	Moteur	Objectif pedagogique
1	Comment s'inscrire a la FSBM ?	Etapes detaillees d'inscription	FAQ (1,00)	Montrer la fiabilite FAQ
2	Quand commencent les examens ?	Sessions hiver/ete + rattrapage	FAQ (1,00)	Confiance maximale
3	Comment avoir une bourse ?	Criteres + montants ONOUSC	FAQ (1,00)	Reponse institutionnelle
4	Quelles sont les filieres ?	7 licences + masters reels	FAQ + base FSBM	Donnees reelles
5	shno hia les filieres ?	Meme reponse en contexte darija	FAQ darija	Multilinguisme
6	salam, ki dayer ?	Accueil chaleureux en darija	FAQ darija (0,90)	Naturel conversationnel
7	What are the programs?	Reponse en anglais	FAQ EN	Support anglais
8	Je suis stresse pour les examens	Conseils + soutien	FAQ empathie (0,80)	Dimension humaine
9	Ou se trouve le service de scolarite ?	Localisation + horaires	Groq + RAG (FAQ faible)	Limite FAQ -> RAG
10	Quels sont les modules du semestre ?	Liste via base modules	Groq + base	Hors corpus FAQ
11	Qui dirige le departement informatique ?	Pr. ADNAOUI Khalid	Base FSBM reelle	Donnee reelle verifiee
12	Qui est le doyen de la FSBM ?	Pr. Abdeslam EL BOUARI	Base FSBM reelle	Donnee reelle
13	Domaines de recherche du Pr. Benlahmer ?	TALN, web semantique...	Base Scholar reelle	Recherche scientifique
14	Combien de professeurs a la FSBM ?	239 enseignants	Base FSBM reelle	Chiffre officiel

#	Question	Reponse attendue	Moteur	Objectif pedagogique
15	Presente la FSBM	Presentation + doyen + chiffres	FAQ + base	Synthese institutionnelle
16	Presente l'Universite Hassan II	Reponse generative	Groq	Connaissance generale
17	Quelle filiere choisir apres le bac ?	Conseil oriente	Groq + RAG	Orientation
18	Quels debouches pour le DI ?	Metiers du developpement	Groq + base careers	Insertion professionnelle
19	Comment retirer mon diplome ?	Procedure + documents	FAQ (1,00)	Procedure administrative
20	Comment obtenir une attestation ?	Reponse approximative -> precision	FAQ (0,58) + Groq	Montrer la nuance
21	kifash ndir l'inscription ?	Etapes en darija	FAQ darija	Procedure multilingue
22	fin kayn emploi du temps ?	Liens emplois du temps	FAQ darija (0,84)	Horaires en darija
23	contact dyal scholarite ?	Coordonnees scholarite	FAQ darija (0,94)	Contact en darija
24	Y a-t-il des clubs etudiants ?	Liste des clubs	Base FSBM	Vie etudiante
25	Quelles sont les actualites ?	Annonces reelles recentes	Base + web fetch	Information a jour
26	Bonjour, qui es-tu ?	Presentation du chatbot	FAQ identite (0,82)	Identite de l'agent
27	Merci beaucoup !	Formule de politesse	FAQ remerciement	Cloture courtoise
28	Question hors sujet (meteo)	Recentrage poli sur la FSBM	FAQ/Groq	Garde-fou de perimetre
29	Question ambigue tres courte	Demande de reformulation + suggestions	FAQ (seuil)	Gestion de l'incertitude
30	Activer le mode IA avance (LLaMA 3)	Reponse generative riche	Groq + RAG	Demonstration du mode LLM

08 CHAPITRE

Chapitre 8 · Partie 7 — Questions Potentielles du Jury

Cinquante questions frequemment posees en soutenance, avec des elements de reponse concis et defendables.

Tableau 13 — 50 questions potentielles du jury et elements de reponse

#	Question du jury	Element de reponse
1	Pourquoi un chatbot pour la FSBM ?	Decharger la scolarite des questions repetitives et offrir un acces 24h/24, multilingue.
2	Pourquoi le TF-IDF et pas seulement un LLM ?	Fiabilite, rapidite (~30 ms), cout nul, fonctionnement hors ligne et explicabilite.
3	Pourquoi Groq ?	Inference LLaMA 3 a tres faible latence, gratuite (quota), sans infrastructure a gerer.
4	Pourquoi la FAQ reste-t-elle utile avec un LLM ?	Elle garantit l'exactitude institutionnelle et reduit les hallucinations via le RAG.
5	Qu'est-ce que le RAG ?	Retrieval-Augmented Generation : on injecte des contextes verifies dans l'invite du LLM.
6	Comment evitez-vous les hallucinations ?	RAG + seuil de confiance + perimetre borne + repli FAQ local.
7	Pourquoi MySQL ?	Donnees academiques fortement relationnelles, integrite forte (ACID), 3NF.
8	Pourquoi MongoDB ?	Conversations et analytics semi-structurees, volumetrie et flexibilite.
9	Pourquoi deux bases (polyglotte) ?	Choisir le bon outil par nature de donnee plutot qu'un modele unique.
10	Pourquoi Angular ?	Framework complet, TypeScript, signals performants, structurant pour un projet de cette taille.
11	Pourquoi FastAPI ?	Asynchrone, validation Pydantic automatique, documentation Swagger generee.
12	Pourquoi une architecture micro-services ?	Decouplage, evolutivite, isolation des pannes, scalabilite par service.
13	Comment garantisiez-vous la disponibilite ?	Cascade de repli Groq -> HuggingFace -> TF-IDF local : 100 % de disponibilite.
14	Quelles langues sont supportees ?	Francais, anglais et darija marocaine (graphie latine et arabe).
15	Comment detectez-vous la langue ?	Detecteur hybride : script arabe, chiffres darija 3/7/9, mots-cles lexicaux.

#	Question du jury	Element de reponse
16	Comment fonctionne le TF-IDF ?	Vectorisation ponderee des termes + similarite cosinus avec les patterns.
17	Qu'est-ce que la similarite cosinus ?	Mesure de l'angle entre deux vecteurs, independante de la norme.
18	Comment est gere le multilinguisme ?	Trois modeles TF-IDF independants, un par langue, aiguilles par la detection.
19	Combien d'intentions reconnait le chatbot ?	28 intentions, ~835 patterns d'entrainement (188 FR, 186 EN, 461 darija).
20	Comment securisez-vous l'administration ?	Authentification JWT + bcrypt, controle d'accès par roles (RBAC).
21	Comment evitez-vous les injections SQL ?	Requetes parametrees via SQLAlchemy, jamais de concatenation.
22	Comment gerez-vous le XSS ?	Angular echappe automatiquement le contenu interpolate.
23	Comment validez-vous les entrees ?	Schemas Pydantic (types, longueurs, formats) cote backend.
24	Ou sont stockes les secrets ?	Dans un fichier .env exclu du depot, jamais dans le code.
25	Quelle est la latence moyenne ?	~150 ms en mode classique, ~250 ms en mode Groq+RAG.
26	Comment avez-vous teste le systeme ?	33 tests automatises (auth, CRUD, moderation, upload) + tests fonctionnels.
27	Les donnees sont-elles reelles ?	Oui pour l'institutionnel (fsbm.ma, Scholar) ; les fiches etudiants sont modelisees (confidentialite).
28	D'ou viennent les donnees professeurs ?	Site officiel fsbm.ma (239 enseignants) + Google Scholar pour 5 profils verifies.
29	Comment la FAQ est-elle alimentee ?	Dataset multilingue + base de connaissances reelle (fsbm_knowledge.json).
30	Que se passe-t-il si Groq tombe ?	Repli automatique vers HuggingFace, puis vers le TF-IDF local.
31	Le chatbot peut-il se tromper ?	Oui : nous l'avons montre (ex. scolarite mal classee). D'ou le seuil et le RAG.
32	Comment gerez-vous une faible confiance ?	Demande de reformulation + suggestions de questions proches.
33	Le systeme apprend-il en continu ?	Pas encore : les questions a faible confiance sont journalisees pour enrichir le dataset.
34	Quelle est la part de la darija ?	461 patterns, soit plus de la moitie du corpus : un differentiateur fort.
35	Comment personnalisez-vous les reponses ?	Detection du genre/nom et substitution de formules (khoya, khti, lalla).
36	Pourquoi pas ChatGPT directement ?	Pas de contexte FSBM, risque d'hallucination, cout, pas de souverainete des donnees.
37	Quelle est la difference avec un FAQ statique ?	Comprehension du langage naturel, multilingue, et complement generatif.
38	Comment l'admin met-il a jour les donnees ?	Espace d'administration securise (CRUD annonces, academique, FAQ, moderation).

#	Question du jury	Element de reponse
39	La plateforme est-elle responsive ?	Oui, avec mode sombre et design adapte mobile.
40	Comment deploieriez-vous en production ?	Reverse proxy nginx + HTTPS, conteneurisation Docker, CI/CD (perspectives).
41	Quelle est la taille du dataset NLP ?	~835 patterns sur 28 intentions, 3 langues.
42	Comment mesurez-vous la qualite ?	Confiance TF-IDF, feedback utilisateur (note 1-5), questions de reference.
43	Quelle note de satisfaction ?	4,5/5 sur l'assistant (avis collectes dans la plateforme).
44	Quelles perspectives d'evolution ?	App mobile, apprentissage continu, embeddings, integration a l'ENT.
45	Pourquoi la Licence Developpement Informatique ?	Le projet mobilise le full-stack, les BDD et l'IA : coeur de cette filiere reelle de la FSBM.
46	Quelle est votre contribution personnelle ?	Architecture, dataset trilingue, RAG, cascade de repli, integration des donnees reelles.
47	Quelles difficultes avez-vous rencontrees ?	Conflits de ports Windows, integrite des donnees reelles, encadrement des hallucinations.
48	Le projet est-il maintenable ?	Oui : code modulaire, separation des responsabilites, documentation complete.
49	Quel est l'impact attendu ?	Acces unifie 24h/24 pour les etudiants, decharge de la scolarite, image modernisee.
50	Que feriez-vous avec plus de temps ?	Synchroniser la FAQ avec le NLP, ajouter la voix, et completer les 239 fiches profs.

“Un bon systeme n'est pas celui qui ne se trompe jamais, mais celui qui sait quand il ne sait pas — et delegue alors a une source fiable.”

— Principe de conception du projet